Lab 1 - Eksperimen Chunking

Dikerjakan dengan Python (pdfplumber + fungsi potong)

PDF 1: 1_Pengantar_Kecerdasan_Buatan.pdf

Langkah 1. Membaca PDF dan memeriksa teks

Berikut 500 karakter pertama hasil baca_pdf():

```
Pengantar Kecerdasan Buatan
Konsep dasar, sejarah, dan jenis-jenis AI
Apa itu Kecerdasan Buatan?
Kecerdasan Buatan (Artificial Intelligence atau AI) adalah cabang ilmu komputer yang
berfokus pada pembuatan sistem yang mampu melakukan tugas-tugas yang biasanya
membutuhkan kecerdasan manusia, seperti belajar, bernalar, memahami bahasa, mengenali
pola, dan mengambil keputusan.
Sejarah Singkat
1950: Alan Turing mengajukan pertanyaan "Dapatkah mesin berpikir?" dan
memperkenalkan Uji Turing.
1956: Ist
```

Pemeriksaan	Hasil
File	1_Pengantar_Kecerdasan_Buatan.pdf
Total karakter	2022
Karakter rusak (U+FFFD)	0
Sisa kode font '(cid:'	8
Jumlah butir daftar	5
Persentase huruf	80%

1_Pengantar_Kecerdasan_Buatan.pdf: PERHATIAN, ditemukan 0 karakter rusak dan 8 sisa kode font; periksa hasil ekstraksi.

Langkah 2. Jumlah chunk tiap pengaturan

Fungsi potong(teks, ukuran, overlap) memakai jendela geser per karakter; langkah = ukuran x (1 - overlap).

Ukuran (karakter)	overlap 10%	overlap 15%	overlap 20%
500	5	5	5
1000	3	3	3
1500	2	2	2

Tabel 1a. Jumlah chunk untuk 3 ukuran x 3 overlap. Makin besar ukuran, makin sedikit chunk; makin besar overlap, makin banyak chunk.

Langkah 3. Chunk acak per ukuran (overlap 15%, seed 42)

Ukuran	Jumlah chunk	Awal di tengah kalimat	Akhir di tengah kalimat	Memotong butir daftar
500	5	4/5 (80%)	4/5 (80%)	3/5 (60%)
1000	3	2/3 (67%)	2/3 (67%)	1/3 (33%)
1500	2	1/2 (50%)	1/2 (50%)	0/2 (0%)

Tabel 1b. Statistik seluruh chunk pada tiap ukuran (bukan hanya yang dicuplik).

Ukuran 500 karakter

Chunk #1 (karakter 0-500) | awal di tengah kalimat: tidak | akhir di tengah kalimat: ya | memotong butir daftar: ya

```
Pengantar Kecerdasan Buatan
Konsep dasar, sejarah, dan jenis-jenis AI
Apa itu Kecerdasan Buatan?
Kecerdasan Buatan (Artificial Intelligence atau AI) adalah cabang ilmu komputer yang
berfokus pada pembuatan sistem yang mampu melakukan tugas-tugas yang biasanya
membutuhkan kecerdasan manusia, seperti belajar, bernalar, memahami bahasa, mengenali
pola, dan mengambil keputusan.
Sejarah Singkat
1950: Alan Turing mengajukan pertanyaan "Dapatkah mesin berpikir?" dan
memperkenalkan Uji Turing.
1956: Ist
```

Chunk #3 (karakter 850-1350) | awal di tengah kalimat: ya | akhir di tengah kalimat: ya | memotong butir daftar: ya

```
atif.
Jenis-jenis AI
(cid:127) AI Sempit (Narrow AI): dirancang untuk satu tugas tertentu, misalnya rekomendasi film
atau pengenalan wajah. Semua AI yang ada saat ini termasuk jenis ini.
(cid:127) AI Umum (Artificial General Intelligence): AI hipotetis yang mampu memahami dan
mempelajari tugas intelektual apa pun seperti manusia.
(cid:127) Superintelligence: AI hipotetis yang melampaui kemampuan manusia di hampir semua
bidang.
Bidang-bidang Utama dalam AI
(cid:127) Machine Learning: sistem belaj
```

Chunk #5 (karakter 1700-2022) | awal di tengah kalimat: ya | akhir di tengah kalimat: tidak | memotong butir daftar: tidak

```
hlian seorang pakar.
Contoh Penerapan dalam Kehidupan Sehari-hari
AI hadir dalam asisten suara di ponsel, rekomendasi video dan musik, filter spam email,
navigasi peta, penerjemahan otomatis, deteksi penipuan kartu kredit, hingga bantuan
diagnosis medis. Banyak di antaranya bekerja di balik layar tanpa disadari pengguna.
```

Ukuran 1000 karakter

Chunk #1 (karakter 0-1000) | awal di tengah kalimat: tidak | akhir di tengah kalimat: ya | memotong butir daftar: tidak

```
Pengantar Kecerdasan Buatan
Konsep dasar, sejarah, dan jenis-jenis AI
Apa itu Kecerdasan Buatan?
Kecerdasan Buatan (Artificial Intelligence atau AI) adalah cabang ilmu komputer yang
berfokus pada pembuatan sistem yang mampu melakukan tugas-tugas yang biasanya
membutuhkan kecerdasan manusia, seperti belajar, bernalar, memahami bahasa, mengenali
pola, dan mengambil keputusan.
Sejarah Singkat
1950: Alan Turing mengajukan pertanyaan "Dapatkah mesin berpikir?" dan
memperkenalkan Uji Turing.
1956: Istilah "Artificial Intelligence" diperkenalkan pada konferensi Dartmouth oleh John
McCarthy dan rekan-rekannya.
1980-an: Sistem pakar (expert system) populer di dunia industri.
1997: Komputer Deep Blue milik IBM mengalahkan juara catur dunia Garry Kasparov.
2012 hingga kini: Kebangkitan deep learning dan, belakangan, model bahasa besar serta
AI generatif.
Jenis-jenis AI
(cid:127) AI Sempit (Narrow AI): dirancang untuk satu tugas tertentu, misalnya rekomendasi film
atau pengenalan wajah. Semua AI y
```

Chunk #2 (karakter 850-1850) | awal di tengah kalimat: ya | akhir di tengah kalimat: ya | memotong butir daftar: ya

```
atif.
Jenis-jenis AI
(cid:127) AI Sempit (Narrow AI): dirancang untuk satu tugas tertentu, misalnya rekomendasi film
atau pengenalan wajah. Semua AI yang ada saat ini termasuk jenis ini.
(cid:127) AI Umum (Artificial General Intelligence): AI hipotetis yang mampu memahami dan
mempelajari tugas intelektual apa pun seperti manusia.
(cid:127) Superintelligence: AI hipotetis yang melampaui kemampuan manusia di hampir semua
bidang.
Bidang-bidang Utama dalam AI
(cid:127) Machine Learning: sistem belajar dari data tanpa diprogram secara eksplisit.
(cid:127) Natural Language Processing (NLP): pemrosesan dan pemahaman bahasa manusia.
(cid:127) Computer Vision: kemampuan mesin memahami gambar dan video.
```

```
(cid:127) Robotika: mesin yang dapat merasakan lingkungan dan bertindak di dalamnya.
(cid:127) Sistem Pakar: sistem berbasis aturan yang meniru keahlian seorang pakar.
Contoh Penerapan dalam Kehidupan Sehari-hari
AI hadir dalam asisten suara di ponsel, rekomendasi video dan musik, filter spam ema
```

Chunk #3 (karakter 1700-2022) | awal di tengah kalimat: ya | akhir di tengah kalimat: tidak | memotong butir daftar: tidak

```
hlian seorang pakar.
Contoh Penerapan dalam Kehidupan Sehari-hari
AI hadir dalam asisten suara di ponsel, rekomendasi video dan musik, filter spam email,
navigasi peta, penerjemahan otomatis, deteksi penipuan kartu kredit, hingga bantuan
diagnosis medis. Banyak di antaranya bekerja di balik layar tanpa disadari pengguna.
```

Ukuran 1500 karakter

Chunk #1 (karakter 0-1500) | awal di tengah kalimat: tidak | akhir di tengah kalimat: ya | memotong butir daftar: tidak

```
Pengantar Kecerdasan Buatan
Konsep dasar, sejarah, dan jenis-jenis AI
Apa itu Kecerdasan Buatan?
Kecerdasan Buatan (Artificial Intelligence atau AI) adalah cabang ilmu komputer yang
berfokus pada pembuatan sistem yang mampu melakukan tugas-tugas yang biasanya
membutuhkan kecerdasan manusia, seperti belajar, bernalar, memahami bahasa, mengenali
pola, dan mengambil keputusan.
Sejarah Singkat
1950: Alan Turing mengajukan pertanyaan "Dapatkah mesin berpikir?" dan
memperkenalkan Uji Turing.
1956: Istilah "Artificial Intelligence" diperkenalkan pada konferensi Dartmouth oleh John
McCarthy dan rekan-rekannya.
1980-an: Sistem pakar (expert system) populer di dunia industri.
1997: Komputer Deep Blue milik IBM mengalahkan juara catur dunia Garry Kasparov.
2012 hingga kini: Kebangkitan deep learning dan, belakangan, model bahasa besar serta
AI generatif.
Jenis-jenis AI
(cid:127) AI Sempit (Narrow AI): dirancang untuk satu tugas tertentu, misalnya rekomendasi film
atau pengenalan wajah. Semua AI yang ada saat ini termasuk jenis ini.
(cid:127) AI Umum (Artificial General Intelligence): AI hipotetis yang mampu memahami dan
mempelajari tugas intelektual apa pun seperti manusia.
(cid:127) Superintelligence: AI hipotetis yang melampaui kemampuan manusia di hampir semua
bidang.
Bidang-bidang Utama dalam AI
(cid:127) Machine Learning: sistem belajar dari data tanpa diprogram secara eksplisit.
(cid:127) Natural Language Processing (NLP): pemrosesan dan pemahaman bahasa manusia.
(cid:127) Compute
```

Chunk #2 (karakter 1275-2022) | awal di tengah kalimat: ya | akhir di tengah kalimat: tidak | memotong butir daftar: tidak

```
dang.
Bidang-bidang Utama dalam AI
(cid:127) Machine Learning: sistem belajar dari data tanpa diprogram secara eksplisit.
(cid:127) Natural Language Processing (NLP): pemrosesan dan pemahaman bahasa manusia.
(cid:127) Computer Vision: kemampuan mesin memahami gambar dan video.
(cid:127) Robotika: mesin yang dapat merasakan lingkungan dan bertindak di dalamnya.
(cid:127) Sistem Pakar: sistem berbasis aturan yang meniru keahlian seorang pakar.
Contoh Penerapan dalam Kehidupan Sehari-hari
AI hadir dalam asisten suara di ponsel, rekomendasi video dan musik, filter spam email,
navigasi peta, penerjemahan otomatis, deteksi penipuan kartu kredit, hingga bantuan
diagnosis medis. Banyak di antaranya bekerja di balik layar tanpa disadari pengguna.
```

PDF 2: 2_Machine_Learning_dan_Deep_Learning.pdf

Langkah 1. Membaca PDF dan memeriksa teks

Berikut 500 karakter pertama hasil baca_pdf():

```
Machine Learning dan Deep Learning
Cara mesin belajar dari data
Machine Learning
Machine Learning (ML) adalah pendekatan AI di mana algoritma menemukan pola dari data,
lalu menggunakan pola tersebut untuk membuat prediksi atau keputusan pada data baru.
Kualitas dan jumlah data sangat memengaruhi hasil model.
Tiga Paradigma Pembelajaran
(cid:127) Supervised Learning: model dilatih dengan data berlabel. Contoh: klasifikasi email spam,
prediksi harga rumah.
(cid:127) Unsupervised Learning: model me
```

Pemeriksaan	Hasil
File	2_Machine_Learning_dan_Deep_Learning.pdf
Total karakter	1929
Karakter rusak (U+FFFD)	0
Sisa kode font '(cid:'	11
Jumlah butir daftar	6
Persentase huruf	80%

2_Machine_Learning_dan_Deep_Learning.pdf: PERHATIAN, ditemukan 0 karakter rusak dan 11 sisa kode font; periksa hasil ekstraksi.

Langkah 2. Jumlah chunk tiap pengaturan

Fungsi potong(teks, ukuran, overlap) memakai jendela geser per karakter; langkah = ukuran x (1 - overlap).

Ukuran (karakter)	overlap 10%	overlap 15%	overlap 20%
500	5	5	5
1000	3	3	3
1500	2	2	2

Tabel 2a. Jumlah chunk untuk 3 ukuran x 3 overlap. Makin besar ukuran, makin sedikit chunk; makin besar overlap, makin banyak chunk.

Langkah 3. Chunk acak per ukuran (overlap 15%, seed 42)

Ukuran	Jumlah chunk	Awal di tengah kalimat	Akhir di tengah kalimat	Memotong butir daftar
500	5	4/5 (80%)	4/5 (80%)	0/5 (0%)
1000	3	2/3 (67%)	2/3 (67%)	1/3 (33%)
1500	2	1/2 (50%)	1/2 (50%)	0/2 (0%)

Tabel 2b. Statistik seluruh chunk pada tiap ukuran (bukan hanya yang dicuplik).

Ukuran 500 karakter

Chunk #1 (karakter 0-500) | awal di tengah kalimat: tidak | akhir di tengah kalimat: ya | memotong butir daftar: tidak

```
Machine Learning dan Deep Learning
Cara mesin belajar dari data
Machine Learning
Machine Learning (ML) adalah pendekatan AI di mana algoritma menemukan pola dari data,
```

```
lalu menggunakan pola tersebut untuk membuat prediksi atau keputusan pada data baru.
Kualitas dan jumlah data sangat memengaruhi hasil model.
Tiga Paradigma Pembelajaran
(cid:127) Supervised Learning: model dilatih dengan data berlabel. Contoh: klasifikasi email spam,
prediksi harga rumah.
(cid:127) Unsupervised Learning: model me
```

Chunk #3 (karakter 850-1350) | awal di tengah kalimat: ya | akhir di tengah kalimat: ya | memotong butir daftar: tidak

```
SVM)
(cid:127) K-Nearest Neighbors (KNN) dan K-Means
(cid:127) Jaringan saraf tiruan (neural network)
Alur Kerja Proyek ML
1. Mendefinisikan masalah dan tujuan.
2. Mengumpulkan dan membersihkan data.
3. Memilih fitur dan model.
4. Melatih model pada data latih.
5. Mengevaluasi pada data uji (akurasi, presisi, recall).
6. Menerapkan model dan memantau kinerjanya.
Deep Learning
Deep Learning adalah bagian dari ML yang menggunakan jaringan saraf tiruan berlapis
banyak. Setiap lapisan mempelajari re
```

Chunk #5 (karakter 1700-1929) | awal di tengah kalimat: ya | akhir di tengah kalimat: tidak | memotong butir daftar: tidak

```
rn.
Tantangan
Beberapa tantangan utama adalah overfitting (model terlalu menghafal data latih), kebutuhan
data dan daya komputasi yang besar, serta sulitnya menjelaskan alasan di balik keputusan
model (masalah interpretabilitas).
```

Ukuran 1000 karakter

Chunk #1 (karakter 0-1000) | awal di tengah kalimat: tidak | akhir di tengah kalimat: ya | memotong butir daftar: ya

```
Machine Learning dan Deep Learning
Cara mesin belajar dari data
Machine Learning
Machine Learning (ML) adalah pendekatan AI di mana algoritma menemukan pola dari data,
lalu menggunakan pola tersebut untuk membuat prediksi atau keputusan pada data baru.
Kualitas dan jumlah data sangat memengaruhi hasil model.
Tiga Paradigma Pembelajaran
(cid:127) Supervised Learning: model dilatih dengan data berlabel. Contoh: klasifikasi email spam,
prediksi harga rumah.
(cid:127) Unsupervised Learning: model mencari struktur pada data tanpa label. Contoh:
pengelompokan pelanggan (clustering).
(cid:127) Reinforcement Learning: agen belajar lewat coba-coba dengan menerima hadiah atau
hukuman. Contoh: AI permainan dan robot.
Algoritma Populer
(cid:127) Regresi linear dan logistik
(cid:127) Pohon keputusan dan Random Forest
(cid:127) Support Vector Machine (SVM)
(cid:127) K-Nearest Neighbors (KNN) dan K-Means
(cid:127) Jaringan saraf tiruan (neural network)
Alur Kerja Proyek ML
1. Mendefinisikan masalah d
```

Chunk #2 (karakter 850-1850) | awal di tengah kalimat: ya | akhir di tengah kalimat: ya | memotong butir daftar: tidak

```
SVM)
(cid:127) K-Nearest Neighbors (KNN) dan K-Means
(cid:127) Jaringan saraf tiruan (neural network)
Alur Kerja Proyek ML
1. Mendefinisikan masalah dan tujuan.
2. Mengumpulkan dan membersihkan data.
3. Memilih fitur dan model.
4. Melatih model pada data latih.
5. Mengevaluasi pada data uji (akurasi, presisi, recall).
6. Menerapkan model dan memantau kinerjanya.
Deep Learning
Deep Learning adalah bagian dari ML yang menggunakan jaringan saraf tiruan berlapis
banyak. Setiap lapisan mempelajari representasi data yang makin abstrak. Pendekatan ini
sangat unggul pada data tidak terstruktur seperti gambar, suara, dan teks.
(cid:127) CNN (Convolutional Neural Network): umum untuk pengolahan gambar.
```

```
(cid:127) RNN dan LSTM: dirancang untuk data berurutan seperti deret waktu.
(cid:127) Transformer: arsitektur yang mendasari model bahasa besar modern.
Tantangan
Beberapa tantangan utama adalah overfitting (model terlalu menghafal data latih), kebutuhan
data dan daya komputasi yang besar, serta su
```

Chunk #3 (karakter 1700-1929) | awal di tengah kalimat: ya | akhir di tengah kalimat: tidak | memotong butir daftar: tidak

```
rn.
Tantangan
Beberapa tantangan utama adalah overfitting (model terlalu menghafal data latih), kebutuhan
data dan daya komputasi yang besar, serta sulitnya menjelaskan alasan di balik keputusan
model (masalah interpretabilitas).
```

Ukuran 1500 karakter

Chunk #1 (karakter 0-1500) | awal di tengah kalimat: tidak | akhir di tengah kalimat: ya | memotong butir daftar: tidak

```
Machine Learning dan Deep Learning
Cara mesin belajar dari data
Machine Learning
Machine Learning (ML) adalah pendekatan AI di mana algoritma menemukan pola dari data,
lalu menggunakan pola tersebut untuk membuat prediksi atau keputusan pada data baru.
Kualitas dan jumlah data sangat memengaruhi hasil model.
Tiga Paradigma Pembelajaran
(cid:127) Supervised Learning: model dilatih dengan data berlabel. Contoh: klasifikasi email spam,
prediksi harga rumah.
(cid:127) Unsupervised Learning: model mencari struktur pada data tanpa label. Contoh:
pengelompokan pelanggan (clustering).
(cid:127) Reinforcement Learning: agen belajar lewat coba-coba dengan menerima hadiah atau
hukuman. Contoh: AI permainan dan robot.
Algoritma Populer
(cid:127) Regresi linear dan logistik
(cid:127) Pohon keputusan dan Random Forest
(cid:127) Support Vector Machine (SVM)
(cid:127) K-Nearest Neighbors (KNN) dan K-Means
(cid:127) Jaringan saraf tiruan (neural network)
Alur Kerja Proyek ML
1. Mendefinisikan masalah dan tujuan.
2. Mengumpulkan dan membersihkan data.
3. Memilih fitur dan model.
4. Melatih model pada data latih.
5. Mengevaluasi pada data uji (akurasi, presisi, recall).
6. Menerapkan model dan memantau kinerjanya.
Deep Learning
Deep Learning adalah bagian dari ML yang menggunakan jaringan saraf tiruan berlapis
banyak. Setiap lapisan mempelajari representasi data yang makin abstrak. Pendekatan ini
sangat unggul pada data tidak terstruktur seperti gambar, suara, dan teks.
(cid:127) CNN (Convoluti
```

Chunk #2 (karakter 1275-1929) | awal di tengah kalimat: ya | akhir di tengah kalimat: tidak | memotong butir daftar: tidak

```
unakan jaringan saraf tiruan berlapis
banyak. Setiap lapisan mempelajari representasi data yang makin abstrak. Pendekatan ini
sangat unggul pada data tidak terstruktur seperti gambar, suara, dan teks.
(cid:127) CNN (Convolutional Neural Network): umum untuk pengolahan gambar.
(cid:127) RNN dan LSTM: dirancang untuk data berurutan seperti deret waktu.
(cid:127) Transformer: arsitektur yang mendasari model bahasa besar modern.
Tantangan
Beberapa tantangan utama adalah overfitting (model terlalu menghafal data latih), kebutuhan
data dan daya komputasi yang besar, serta sulitnya menjelaskan alasan di balik keputusan
model (masalah interpretabilitas).
```

PDF 3: 3_Etika_dan_Masa_Depan_AI.pdf

Langkah 1. Membaca PDF dan memeriksa teks

Berikut 500 karakter pertama hasil baca_pdf():

```
Etika dan Masa Depan Kecerdasan Buatan
Peluang, risiko, dan tata kelola AI
Mengapa Etika AI Penting?
Seiring AI dipakai dalam keputusan yang memengaruhi manusia, seperti rekrutmen,
pemberian kredit, layanan kesehatan, dan penegakan hukum, muncul kebutuhan untuk
memastikan sistem ini adil, aman, dan bertanggung jawab.
Isu Etika Utama
(cid:127) Bias dan diskriminasi: model dapat mewarisi bias dari data latih sehingga menghasilkan
keputusan yang tidak adil.
(cid:127) Privasi: pengumpulan data priba
```

Pemeriksaan	Hasil
File	3_Etika_dan_Masa_Depan_AI.pdf
Total karakter	2033
Karakter rusak (U+FFFD)	0
Sisa kode font '(cid:'	12
Jumlah butir daftar	0
Persentase huruf	81%

3_Etika_dan_Masa_Depan_AI.pdf: PERHATIAN, ditemukan 0 karakter rusak dan 12 sisa kode font; periksa hasil ekstraksi.

Langkah 2. Jumlah chunk tiap pengaturan

Fungsi potong(teks, ukuran, overlap) memakai jendela geser per karakter; langkah = ukuran x (1 - overlap).

Ukuran (karakter)	overlap 10%	overlap 15%	overlap 20%
500	5	5	5
1000	3	3	3
1500	2	2	2

Tabel 3a. Jumlah chunk untuk 3 ukuran x 3 overlap. Makin besar ukuran, makin sedikit chunk; makin besar overlap, makin banyak chunk.

Langkah 3. Chunk acak per ukuran (overlap 15%, seed 42)

Ukuran	Jumlah chunk	Awal di tengah kalimat	Akhir di tengah kalimat	Memotong butir daftar
500	5	4/5 (80%)	4/5 (80%)	0/5 (0%)
1000	3	2/3 (67%)	2/3 (67%)	0/3 (0%)
1500	2	1/2 (50%)	1/2 (50%)	0/2 (0%)

Tabel 3b. Statistik seluruh chunk pada tiap ukuran (bukan hanya yang dicuplik).

Ukuran 500 karakter

Chunk #1 (karakter 0-500) | awal di tengah kalimat: tidak | akhir di tengah kalimat: ya | memotong butir daftar: tidak

```
Etika dan Masa Depan Kecerdasan Buatan
Peluang, risiko, dan tata kelola AI
Mengapa Etika AI Penting?
Seiring AI dipakai dalam keputusan yang memengaruhi manusia, seperti rekrutmen,
```

```
pemberian kredit, layanan kesehatan, dan penegakan hukum, muncul kebutuhan untuk
memastikan sistem ini adil, aman, dan bertanggung jawab.
Isu Etika Utama
(cid:127) Bias dan diskriminasi: model dapat mewarisi bias dari data latih sehingga menghasilkan
keputusan yang tidak adil.
(cid:127) Privasi: pengumpulan data priba
```

Chunk #2 (karakter 425-925) | awal di tengah kalimat: ya | akhir di tengah kalimat: ya | memotong butir daftar: tidak

```
silkan
keputusan yang tidak adil.
(cid:127) Privasi: pengumpulan data pribadi dalam skala besar menimbulkan risiko
penyalahgunaan.
(cid:127) Transparansi: sulit memahami alasan keputusan model yang kompleks.
(cid:127) Akuntabilitas: siapa yang bertanggung jawab ketika sistem AI membuat kesalahan?
(cid:127) Misinformasi: AI generatif dapat membuat konten palsu yang meyakinkan, termasuk
deepfake.
(cid:127) Hak cipta: pertanyaan mengenai data pelatihan dan kepemilikan hasil karya.
Dampak terhadap P
```

Chunk #3 (karakter 850-1350) | awal di tengah kalimat: ya | akhir di tengah kalimat: ya | memotong butir daftar: tidak

```
yaan mengenai data pelatihan dan kepemilikan hasil karya.
Dampak terhadap Pekerjaan
AI cenderung mengotomatisasi tugas-tugas rutin dan sekaligus menciptakan peran baru.
Banyak pekerjaan akan berubah isinya daripada hilang sepenuhnya, sehingga peningkatan
keterampilan (upskilling) dan literasi digital menjadi sangat penting.
Prinsip AI yang Bertanggung Jawab
(cid:127) Keadilan dan tidak diskriminatif
(cid:127) Keamanan dan ketahanan
(cid:127) Privasi dan perlindungan data
(cid:127) Transparansi d
```

Ukuran 1000 karakter

Chunk #1 (karakter 0-1000) | awal di tengah kalimat: tidak | akhir di tengah kalimat: ya | memotong butir daftar: tidak

```
Etika dan Masa Depan Kecerdasan Buatan
Peluang, risiko, dan tata kelola AI
Mengapa Etika AI Penting?
Seiring AI dipakai dalam keputusan yang memengaruhi manusia, seperti rekrutmen,
pemberian kredit, layanan kesehatan, dan penegakan hukum, muncul kebutuhan untuk
memastikan sistem ini adil, aman, dan bertanggung jawab.
Isu Etika Utama
(cid:127) Bias dan diskriminasi: model dapat mewarisi bias dari data latih sehingga menghasilkan
keputusan yang tidak adil.
(cid:127) Privasi: pengumpulan data pribadi dalam skala besar menimbulkan risiko
penyalahgunaan.
(cid:127) Transparansi: sulit memahami alasan keputusan model yang kompleks.
(cid:127) Akuntabilitas: siapa yang bertanggung jawab ketika sistem AI membuat kesalahan?
(cid:127) Misinformasi: AI generatif dapat membuat konten palsu yang meyakinkan, termasuk
deepfake.
(cid:127) Hak cipta: pertanyaan mengenai data pelatihan dan kepemilikan hasil karya.
Dampak terhadap Pekerjaan
AI cenderung mengotomatisasi tugas-tugas rutin dan sekaligus menci
```

Chunk #2 (karakter 850-1850) | awal di tengah kalimat: ya | akhir di tengah kalimat: ya | memotong butir daftar: tidak

```
yaan mengenai data pelatihan dan kepemilikan hasil karya.
Dampak terhadap Pekerjaan
AI cenderung mengotomatisasi tugas-tugas rutin dan sekaligus menciptakan peran baru.
Banyak pekerjaan akan berubah isinya daripada hilang sepenuhnya, sehingga peningkatan
keterampilan (upskilling) dan literasi digital menjadi sangat penting.
Prinsip AI yang Bertanggung Jawab
(cid:127) Keadilan dan tidak diskriminatif
(cid:127) Keamanan dan ketahanan
(cid:127) Privasi dan perlindungan data
(cid:127) Transparansi dan keterjelasan
(cid:127) Pengawasan manusia
(cid:127) Akuntabilitas
Tata Kelola dan Regulasi
Berbagai negara dan organisasi menyusun kerangka pengaturan AI, misalnya EU AI Act di
Uni Eropa serta pedoman etika dari UNESCO dan OECD. Indonesia juga mengembangkan
Strategi Nasional Kecerdasan Artifisial serta panduan etika terkait. Detail regulasi terus
```

```
berkembang, sehingga perlu dicek ke sumber resmi terbaru.
Menatap ke Depan
Arah pengembangan AI mencakup sistem yang lebih mampu bernalar, AI multim
```

Chunk #3 (karakter 1700-2033) | awal di tengah kalimat: ya | akhir di tengah kalimat: tidak | memotong butir daftar: tidak

```
s
berkembang, sehingga perlu dicek ke sumber resmi terbaru.
Menatap ke Depan
Arah pengembangan AI mencakup sistem yang lebih mampu bernalar, AI multimodal (teks,
gambar, suara), serta agen AI yang dapat menjalankan tugas secara mandiri. Kunci masa
depan yang baik adalah kolaborasi antara teknolog, pembuat kebijakan, dan masyarakat.
```

Ukuran 1500 karakter

Chunk #1 (karakter 0-1500) | awal di tengah kalimat: tidak | akhir di tengah kalimat: ya | memotong butir daftar: tidak

```
Etika dan Masa Depan Kecerdasan Buatan
Peluang, risiko, dan tata kelola AI
Mengapa Etika AI Penting?
Seiring AI dipakai dalam keputusan yang memengaruhi manusia, seperti rekrutmen,
pemberian kredit, layanan kesehatan, dan penegakan hukum, muncul kebutuhan untuk
memastikan sistem ini adil, aman, dan bertanggung jawab.
Isu Etika Utama
(cid:127) Bias dan diskriminasi: model dapat mewarisi bias dari data latih sehingga menghasilkan
keputusan yang tidak adil.
(cid:127) Privasi: pengumpulan data pribadi dalam skala besar menimbulkan risiko
penyalahgunaan.
(cid:127) Transparansi: sulit memahami alasan keputusan model yang kompleks.
(cid:127) Akuntabilitas: siapa yang bertanggung jawab ketika sistem AI membuat kesalahan?
(cid:127) Misinformasi: AI generatif dapat membuat konten palsu yang meyakinkan, termasuk
deepfake.
(cid:127) Hak cipta: pertanyaan mengenai data pelatihan dan kepemilikan hasil karya.
Dampak terhadap Pekerjaan
AI cenderung mengotomatisasi tugas-tugas rutin dan sekaligus menciptakan peran baru.
Banyak pekerjaan akan berubah isinya daripada hilang sepenuhnya, sehingga peningkatan
keterampilan (upskilling) dan literasi digital menjadi sangat penting.
Prinsip AI yang Bertanggung Jawab
(cid:127) Keadilan dan tidak diskriminatif
(cid:127) Keamanan dan ketahanan
(cid:127) Privasi dan perlindungan data
(cid:127) Transparansi dan keterjelasan
(cid:127) Pengawasan manusia
(cid:127) Akuntabilitas
Tata Kelola dan Regulasi
Berbagai negara dan organisasi menyusun kerangka pengatu
```

Chunk #2 (karakter 1275-2033) | awal di tengah kalimat: ya | akhir di tengah kalimat: tidak | memotong butir daftar: tidak

```
ketahanan
(cid:127) Privasi dan perlindungan data
(cid:127) Transparansi dan keterjelasan
(cid:127) Pengawasan manusia
(cid:127) Akuntabilitas
Tata Kelola dan Regulasi
Berbagai negara dan organisasi menyusun kerangka pengaturan AI, misalnya EU AI Act di
Uni Eropa serta pedoman etika dari UNESCO dan OECD. Indonesia juga mengembangkan
Strategi Nasional Kecerdasan Artifisial serta panduan etika terkait. Detail regulasi terus
berkembang, sehingga perlu dicek ke sumber resmi terbaru.
Menatap ke Depan
Arah pengembangan AI mencakup sistem yang lebih mampu bernalar, AI multimodal (teks,
gambar, suara), serta agen AI yang dapat menjalankan tugas secara mandiri. Kunci masa
depan yang baik adalah kolaborasi antara teknolog, pembuat kebijakan, dan masyarakat.
```

Kesimpulan

Pemotongan per karakter tidak mengenal batas kalimat maupun butir daftar. Gabungan ketiga PDF (overlap 15%) - ukuran 500: 15 chunk, awal di tengah kalimat 12/15 (80%), akhir di tengah kalimat 12/15 (80%), memotong butir daftar 3/15 (20%); ukuran 1000: 9 chunk, awal di tengah kalimat 6/9 (67%), akhir di tengah kalimat 6/9 (67%), memotong butir daftar 2/9 (22%); ukuran 1500: 6 chunk, awal di tengah kalimat 3/6 (50%), akhir di tengah kalimat 3/6 (50%), memotong butir daftar 0/6 (0%). Persentase chunk yang berakhir di tengah kalimat turun saat ukuran diperbesar dari 500 ke 1500 karakter (80% menjadi 50%), sedangkan jumlah chunk turun dari 15 menjadi 6 dan tiap chunk memuat lebih banyak topik. Dokumen ini pendek (rata-rata 1,994 karakter), sehingga ukuran 1500 hanya menghasilkan sedikit chunk dan angkanya kasar. Chunk pertama selalu bersih di awal karena dimulai dari posisi 0. Karena isinya penuh daftar poin, butir yang terpisah dari kalimat pembukanya kehilangan konteks. Perbaikan yang layak dicoba: pemotongan berbasis kalimat/paragraf dan memperlakukan satu butir daftar (beserta judul bagiannya) sebagai satu kesatuan.

Lampiran: kode lab1_chunking.py

```
"""Lab 1 - Eksperimen chunking (15 menit).

1. Baca tiap PDF dengan baca_pdf() dan cetak 500 karakter pertama.
2. Potong dengan potong() memakai tiga ukuran (500, 1000, 1500) dan overlap 10-20%.
3. Lihat 3 chunk acak tiap ukuran: terpotong di tengah kalimat atau daftar poin?

Dokumen yang dipakai (3 PDF tentang kecerdasan buatan, taruh di FOLDER_DOKUMEN
atau di folder yang sama dengan file ini):
  - 1_Pengantar_Kecerdasan_Buatan.pdf
  - 2_Machine_Learning_dan_Deep_Learning.pdf
  - 3_Etika_dan_Masa_Depan_AI.pdf
Ketiganya tidak berisi tabel, tetapi penuh daftar poin (bullet, nomor, dan butir
bertahun seperti "1950: ..."). Karena itu yang diperiksa pada langkah 3 adalah
apakah chunk memotong sebuah butir daftar, bukan tabel.
"""
import os
import random
import re
import sys

sys.path.insert(0, os.path.dirname(os.path.abspath(__file__)))
from laporan_utils import Laporan
from rag_utils import FOLDER_DOKUMEN, baca_pdf, potong, potong_dengan_posisi

BASE = os.path.dirname(os.path.abspath(__file__))
NAMA_PDF = [
    "1_Pengantar_Kecerdasan_Buatan.pdf",
    "2_Machine_Learning_dan_Deep_Learning.pdf",
    "3_Etika_dan_Masa_Depan_AI.pdf",
]
UKURAN = [500, 1000, 1500]
OVERLAP = [0.10, 0.15, 0.20]
OVERLAP_UTAMA = 0.15
SEED = 42

# Awal butir daftar: "• ...", "1. ...", "1950: ...", "1980-an: ...", "2012 hingga ..."
POLA_BUTIR = re.compile(r"^(•\s|\d+\.\s|\d{4}(-an)?\b)")
# Baris butir yang panjang dan tidak berakhir tanda baca dianggap berlanjut ke baris berikutnya
PANJANG_BARIS_LANJUT = 70


def cari_pdf(nama):
    """Cari file di FOLDER_DOKUMEN, lalu di folder skrip ini."""
    for folder in (FOLDER_DOKUMEN, BASE):
        path = os.path.join(folder, nama)
        if os.path.exists(path):
            return path
    raise FileNotFoundError(f"{nama} tidak ditemukan di {FOLDER_DOKUMEN} maupun {BASE}")


def wilayah_daftar(teks):
    """Cari rentang karakter tiap butir daftar (baris butir + baris lanjutannya)."""
    baris, pos = [], 0
    for b in teks.split("\n"):
        baris.append((pos, pos + len(b), b))
        pos += len(b) + 1
    hasil, i = [], 0
    while i < len(baris):
        mulai, akhir, isi = baris[i]
        if POLA_BUTIR.match(isi):
            j = i
            while (j + 1 < len(baris)
                   and len(baris[j][2]) >= PANJANG_BARIS_LANJUT
                   and baris[j][2].rstrip()[-1:] not in ".!?"
                   and not POLA_BUTIR.match(baris[j + 1][2])):
                j += 1
            hasil.append((mulai, baris[j][1]))
            i = j + 1
        else:
            i += 1
    return hasil


def awal_di_tengah_kalimat(teks, mulai):
    """Chunk dimulai di tengah kalimat bila karakter bermakna sebelumnya bukan akhir kalimat/baris."""
    sebelum = teks[:mulai].rstrip(" ")
    return bool(sebelum) and sebelum[-1] not in ".!?:\n"


def akhir_di_tengah_kalimat(teks, akhir):
```

```
    ujung = teks[:akhir].rstrip()
    return bool(ujung) and ujung[-1] not in ".!?"


def memotong_daftar(wil, mulai, akhir):
    """True bila chunk beririsan dengan sebuah butir daftar tetapi tidak memuat butir itu seluruhnya."""
    for a, b in wil:
        beririsan = mulai < b and akhir > a
        utuh = mulai <= a and akhir >= b
        if beririsan and not utuh:
            return True
    return False


def persen(x, n):
    return f"{x}/{n} ({x / n:.0%})"


def analisis_pdf(nama, rnd):
    """Jalankan langkah 1-3 untuk satu PDF dan kembalikan semua hasilnya."""
    path = cari_pdf(nama)
    teks = baca_pdf(path)
    n_huruf = sum(c.isalpha() for c in teks)
    kualitas = {
        "File": nama,
        "Total karakter": len(teks),
        "Karakter rusak (U+FFFD)": teks.count("\ufffd"),
        "Sisa kode font '(cid:'": teks.count("(cid:"),
        "Jumlah butir daftar": len(wilayah_daftar(teks)),
        "Persentase huruf": f"{n_huruf / len(teks):.0%}",
    }
    print(f"\n########## {nama} ##########")
    print("=== Langkah 1: 500 karakter pertama ===")
    print(teks[:500])
    print(kualitas)

    print("\n=== Langkah 2: jumlah chunk ===")
    tabel_jumlah = [["Ukuran (karakter)"] + [f"overlap {int(o * 100)}%" for o in OVERLAP]]
    for u in UKURAN:
        baris = [u]
        for o in OVERLAP:
            n = len(potong(teks, u, o))
            baris.append(n)
            print(f"ukuran={u:5d} overlap={o:.0%} -> {n} chunk")
        tabel_jumlah.append(baris)

    wil = wilayah_daftar(teks)
    cuplikan = {}
    statistik = [["Ukuran", "Jumlah chunk", "Awal di tengah kalimat",
                  "Akhir di tengah kalimat", "Memotong butir daftar"]]
    mentah = {}  # ukuran -> (n, awal, akhir, daftar) untuk kesimpulan gabungan
    for u in UKURAN:
        pot = potong_dengan_posisi(teks, u, OVERLAP_UTAMA)
        n = len(pot)
        a = sum(awal_di_tengah_kalimat(teks, m) for m, _, _ in pot)
        z = sum(akhir_di_tengah_kalimat(teks, e) for _, e, _ in pot)
        t = sum(memotong_daftar(wil, m, e) for m, e, _ in pot)
        mentah[u] = (n, a, z, t)
        statistik.append([u, n, persen(a, n), persen(z, n), persen(t, n)])
        pilih = sorted(rnd.sample(range(n), min(3, n)))
        cuplikan[u] = [(i + 1, pot[i][0], pot[i][1], pot[i][2],
                        awal_di_tengah_kalimat(teks, pot[i][0]),
                        akhir_di_tengah_kalimat(teks, pot[i][1]),
                        memotong_daftar(wil, pot[i][0], pot[i][1])) for i in pilih]
        print(f"\n=== Langkah 3: ukuran {u} ({len(pilih)} chunk acak) ===")
        for no, m, e, isi, aw, ak, dp in cuplikan[u]:
            print(f"--- chunk #{no} [{m}:{e}] awal_tengah={aw} akhir_tengah={ak} potong_daftar={dp}")
            print(isi)

    return dict(nama=nama, teks=teks, kualitas=kualitas, tabel_jumlah=tabel_jumlah,
                statistik=statistik, cuplikan=cuplikan, mentah=mentah)


def catatan_kualitas(hasil):
    """Catatan kualitas teks yang dihitung dari angka, bukan ditulis tetap."""
    k = hasil["kualitas"]
    if k["Karakter rusak (U+FFFD)"] == 0 and k["Sisa kode font '(cid:'"] == 0:
        return (f"{hasil['nama']}: teks terbaca bersih, tidak ada karakter rusak maupun sisa kode font. "
                f"Terdeteksi {k['Jumlah butir daftar']} butir daftar.")
    return (f"{hasil['nama']}: PERHATIAN, ditemukan {k['Karakter rusak (U+FFFD)']} karakter rusak dan "
            f"{k['Sisa kode font ' + chr(39) + '(cid:' + chr(39)]} sisa kode font; periksa hasil
    ekstraksi.")
def buat_kesimpulan(semua):
```

```
    """Gabungkan statistik seluruh PDF per ukuran, lalu susun kesimpulan dari angkanya."""
    gabung = {}
    for u in UKURAN:
        n = sum(h["mentah"][u][0] for h in semua)
        a = sum(h["mentah"][u][1] for h in semua)
        z = sum(h["mentah"][u][2] for h in semua)
        t = sum(h["mentah"][u][3] for h in semua)
        gabung[u] = (n, a, z, t)
    rincian = "; ".join(
        f"ukuran {u}: {gabung[u][0]} chunk, awal di tengah kalimat {persen(gabung[u][1], gabung[u][0])},
    "
        f"akhir di tengah kalimat {persen(gabung[u][2], gabung[u][0])}, "
        f"memotong butir daftar {persen(gabung[u][3], gabung[u][0])}"
        for u in UKURAN)
    n_kecil, n_besar = gabung[UKURAN[0]][0], gabung[UKURAN[-1]][0]
    pz_kecil = gabung[UKURAN[0]][2] / n_kecil
    pz_besar = gabung[UKURAN[-1]][2] / n_besar
    rata = sum(len(h["teks"]) for h in semua) // len(semua)
    arah = "turun" if pz_besar < pz_kecil - 0.05 else "naik" if pz_besar > pz_kecil + 0.05 else "hampir
    tidak berubah"
    return (
        "Pemotongan per karakter tidak mengenal batas kalimat maupun butir daftar. Gabungan ketiga PDF "
        f"(overlap {int(OVERLAP_UTAMA * 100)}%) - {rincian}. "
        f"Persentase chunk yang berakhir di tengah kalimat {arah} saat ukuran diperbesar dari "
        f"{UKURAN[0]} ke {UKURAN[-1]} karakter ({pz_kecil:.0%} menjadi {pz_besar:.0%}), sedangkan jumlah
    chunk "
        f"turun dari {n_kecil} menjadi {n_besar} dan tiap chunk memuat lebih banyak topik. "
        f"Dokumen ini pendek (rata-rata {rata:,} karakter), sehingga ukuran {UKURAN[-1]} hanya "
        "menghasilkan sedikit chunk dan angkanya kasar. "
        "Chunk pertama selalu bersih di awal karena dimulai dari posisi 0. Karena isinya penuh daftar
    poin, "
        "butir yang terpisah dari kalimat pembukanya kehilangan konteks. Perbaikan yang layak dicoba: "
        "pemotongan berbasis kalimat/paragraf dan memperlakukan satu butir daftar (beserta judul
    bagiannya) "
        "sebagai satu kesatuan."
    )


def main():
    rnd = random.Random(SEED)
    semua = [analisis_pdf(nama, rnd) for nama in NAMA_PDF]
    kesimpulan = buat_kesimpulan(semua)
    print("\nKesimpulan:", kesimpulan)

    L = Laporan(os.path.join(BASE, "Lab1_Eksperimen_Chunking.pdf"),
                "Lab 1 - Eksperimen Chunking", "Dikerjakan dengan Python (pdfplumber + fungsi potong)")
    for no_pdf, h in enumerate(semua, 1):
        L.h1(f"PDF {no_pdf}: {h['nama']}")
        L.h2("Langkah 1. Membaca PDF dan memeriksa teks")
        L.p("Berikut 500 karakter pertama hasil baca_pdf():")
        L.kode(h["teks"][:500])
        L.spasi()
        L.tabel([["Pemeriksaan", "Hasil"]] + [[k, v] for k, v in h["kualitas"].items()],
                [6 * 28.35, 8 * 28.35])
        L.p(catatan_kualitas(h))
        L.h2("Langkah 2. Jumlah chunk tiap pengaturan")
        L.p("Fungsi potong(teks, ukuran, overlap) memakai jendela geser per karakter; "
            "langkah = ukuran x (1 - overlap).")
        L.tabel(h["tabel_jumlah"])
        L.cap(f"Tabel {no_pdf}a. Jumlah chunk untuk 3 ukuran x 3 overlap. Makin besar ukuran, makin
    sedikit "
              "chunk; makin besar overlap, makin banyak chunk.")
        L.h2(f"Langkah 3. Chunk acak per ukuran (overlap {int(OVERLAP_UTAMA * 100)}%, seed {SEED})")
        L.tabel(h["statistik"])
        L.cap(f"Tabel {no_pdf}b. Statistik seluruh chunk pada tiap ukuran (bukan hanya yang dicuplik).")
        for u in UKURAN:
            L.p(f"Ukuran {u} karakter")
            for no, m, e, isi, aw, ak, dp in h["cuplikan"][u]:
                L.p(f"Chunk #{no} (karakter {m}-{e}) | awal di tengah kalimat: {'ya' if aw else 'tidak'}
    | "
                    f"akhir di tengah kalimat: {'ya' if ak else 'tidak'} | "
                    f"memotong butir daftar: {'ya' if dp else 'tidak'}")
                L.kode(isi)
                L.spasi(4)
        L.halaman_baru()
    L.h1("Kesimpulan")
    L.p(kesimpulan)
    L.halaman_baru()
    L.h1("Lampiran: kode lab1_chunking.py")
    L.kode(open(__file__, encoding="utf-8").read())
    L.simpan()
    print("\nLaporan: Lab1_Eksperimen_Chunking.pdf")
if __name__ == "__main__":
```

```
main()
```