Lab 2 - Bangun Indeks & Cari

ukuran chunk 1000, overlap 15%, backend: lsa

Langkah 1. Membangun indeks

Tiga PDF diletakkan di folder dokumen/. Setiap file melaporkan jumlah chunk-nya:

File	Jumlah chunk
1_Pengantar_Kecerdasan_Buatan.pdf	3
2_Machine_Learning_dan_Deep_Learning.pdf	3
3_Etika_dan_Masa_Depan_AI.pdf	3
Total	9

```
1_Pengantar_Kecerdasan_Buatan.pdf: 3 chunk
2_Machine_Learning_dan_Deep_Learning.pdf: 3 chunk
3_Etika_dan_Masa_Depan_AI.pdf: 3 chunk
Total 9 chunk | ukuran=1000 overlap=15% | backend=lsa
```

Langkah 2. Lima pertanyaan dan pemeriksaan chunk teratas

Sebuah chunk dianggap relevan bila memuat semua kata kunci jawaban. Tabel menunjukkan 3 chunk teratas.

Siapa yang memperkenalkan istilah Artificial Intelligence dan pada tahun berapa? (jawaban di PDF 1)

Peringkat	Skor	Sumber	Relevan?	Cuplikan
1	0.963	1_Pengantar_Kecerdasan_Buatan.pdf #0	ya	Pengantar Kecerdasan Buatan Konsep dasar, sejarah, dan jenis-jenis AI Apa itu Kecerdasan Buatan? Kecerdasan Buatan (Artificial Intelligence ...
2	0.561	1_Pengantar_Kecerdasan_Buatan.pdf #1	tidak	atif. Jenis-jenis AI (cid:127) AI Sempit (Narrow AI): dirancang untuk satu tugas tertentu, misalnya rekomendasi film atau pengenalan wajah. ...
3	0.315	3_Etika_dan_Masa_Depan_AI.pdf #0	tidak	Etika dan Masa Depan Kecerdasan Buatan Peluang, risiko, dan tata kelola AI Mengapa Etika AI Penting? Seiring AI dipakai dalam keputusan yang...

Komputer apa yang mengalahkan juara catur dunia Garry Kasparov? (jawaban di PDF 1)

Peringkat	Skor	Sumber	Relevan?	Cuplikan
1	0.982	1_Pengantar_Kecerdasan_Buatan.pdf #0	ya	Pengantar Kecerdasan Buatan Konsep dasar, sejarah, dan jenis-jenis AI Apa itu Kecerdasan Buatan? Kecerdasan Buatan (Artificial Intelligence ...
2	0.265	3_Etika_dan_Masa_Depan_AI.pdf #0	tidak	Etika dan Masa Depan Kecerdasan Buatan Peluang, risiko, dan tata kelola AI Mengapa Etika AI Penting? Seiring AI dipakai dalam keputusan yang...
3	0.263	2_Machine_Learning_dan_Deep_Learning.pdf #1	tidak	SVM) (cid:127) K-Nearest Neighbors (KNN) dan K-Means (cid:127) Jaringan saraf tiruan (neural network) Alur Kerja Proyek ML 1. Mendefinisikan...

Apa perbedaan supervised learning dan unsupervised learning? (jawaban di PDF 2)

Peringkat	Skor	Sumber	Relevan?	Cuplikan
1	0.985	2_Machine_Learning_dan_Deep_Learning.pdf #0	ya	Machine Learning dan Deep Learning Cara mesin belajar dari data Machine Learning Machine Learning (ML) adalah pendekatan AI di mana algoritm...
2	0.308	2_Machine_Learning_dan_Deep_Learning.pdf #1	tidak	SVM) (cid:127) K-Nearest Neighbors (KNN) dan K-Means (cid:127) Jaringan saraf tiruan (neural network) Alur Kerja Proyek ML 1. Mendefinisikan...
3	0.281	1_Pengantar_Kecerdasan_Buatan.pdf #1	tidak	atif. Jenis-jenis AI (cid:127) AI Sempit (Narrow AI): dirancang untuk satu tugas tertentu, misalnya rekomendasi film atau pengenalan wajah. ...

Apa yang dimaksud dengan overfitting? (jawaban di PDF 2)

Peringkat	Skor	Sumber	Relevan?	Cuplikan
1	0.967	2_Machine_Learning_dan_Deep_Learning.pdf #2	ya	rn. Tantangan Beberapa tantangan utama adalah overfitting (model terlalu menghafal data latih), kebutuhan data dan daya komputasi yang besar...
2	0.576	2_Machine_Learning_dan_Deep_Learning.pdf #1	ya	SVM) (cid:127) K-Nearest Neighbors (KNN) dan K-Means (cid:127) Jaringan saraf tiruan (neural network) Alur Kerja Proyek ML 1. Mendefinisikan...
3	0.375	3_Etika_dan_Masa_Depan_AI.pdf #0	tidak	Etika dan Masa Depan Kecerdasan Buatan Peluang, risiko, dan tata kelola AI Mengapa Etika AI Penting? Seiring AI dipakai dalam keputusan yang...

Arsitektur apa yang mendasari model bahasa besar modern? (jawaban di PDF 2)

Peringkat	Skor	Sumber	Relevan?	Cuplikan
1	0.945	2_Machine_Learning_dan_Deep_Learning.pdf #1	ya	SVM) (cid:127) K-Nearest Neighbors (KNN) dan K-Means (cid:127) Jaringan saraf tiruan (neural network) Alur Kerja Proyek ML 1. Mendefinisikan...
2	0.502	2_Machine_Learning_dan_Deep_Learning.pdf #2	tidak	rn. Tantangan Beberapa tantangan utama adalah overfitting (model terlalu menghafal data latih), kebutuhan data dan daya komputasi yang besar...
3	0.481	1_Pengantar_Kecerdasan_Buatan.pdf #0	tidak	Pengantar Kecerdasan Buatan Konsep dasar, sejarah, dan jenis-jenis AI Apa itu Kecerdasan Buatan? Kecerdasan Buatan (Artificial Intelligence ...

Ringkasan: chunk peringkat 1 relevan pada 5/5 pertanyaan; ada chunk relevan di 3 teratas pada 5/5.

Langkah 3. Pertanyaan berparafrase

Dua pertanyaan memakai kata yang berbeda dari teks dokumen. Dibandingkan: pencarian semantik (lsa) vs TF-IDF.

Pertanyaan	Catatan	lsa: top1 / top3	TF-IDF: top1 / top3
Bagaimana komputer bisa belajar dari contoh tanpa diberi aturan langkah demi langkah?	Teks memakai 'tanpa diprogram secara eksplisit'; pertanyaan memakai 'tanpa diberi aturan langkah demi langkah'.	ya / ya	ya / ya
Mengapa program komputer bisa memperlakukan kelompok orang tertentu secara berbeda?	Teks memakai 'bias', 'diskriminasi', dan 'mewarisi'; pertanyaan memakai 'memperlakukan kelompok tertentu secara berbeda'.	tidak / ya	tidak / tidak

Chunk teratas untuk "Bagaimana komputer bisa belajar dari contoh tanpa diberi aturan langkah demi langkah?": 1_Pengantar_Kecerdasan_Buatan.pdf #1 (skor 0.831)

```
atif. Jenis-jenis AI (cid:127) AI Sempit (Narrow AI): dirancang untuk satu tugas tertentu, misalnya
    rekomendasi film atau pengenalan wajah. Semua AI yang ada saat ini termasuk jenis ini. (cid:127) AI
    Umum (Artificial General Intelligence): AI hipotetis yang mampu memahami dan mempelajari tugas
    intelektual apa pun seperti manusia. (cid:127) Superintelligence: AI hipotetis yang melampaui
    kemampuan m...
```

Chunk teratas untuk "Mengapa program komputer bisa memperlakukan kelompok orang tertentu secara berbeda?": 1_Pengantar_Kecerdasan_Buatan.pdf #1 (skor 0.790)

```
atif. Jenis-jenis AI (cid:127) AI Sempit (Narrow AI): dirancang untuk satu tugas tertentu, misalnya
    rekomendasi film atau pengenalan wajah. Semua AI yang ada saat ini termasuk jenis ini. (cid:127) AI
    Umum (Artificial General Intelligence): AI hipotetis yang mampu memahami dan mempelajari tugas
    intelektual apa pun seperti manusia. (cid:127) Superintelligence: AI hipotetis yang melampaui
    kemampuan m...
```

Kesimpulan

Pada 5 pertanyaan langsung, chunk peringkat 1 relevan pada 5/5 pertanyaan dan salah satu dari 3 chunk teratas relevan pada 5/5 pertanyaan. Pada 2 pertanyaan parafrase, backend 'lsa' menemukan chunk relevan di peringkat 1 pada 1/2 dan di 3 teratas pada 2/2, sedangkan pembanding TF-IDF (kecocokan bentuk kata) 1/2 dan 1/2. Perlu diingat korpusnya sangat kecil: hanya 9 chunk dari 3 PDF, sehingga 3 chunk teratas sudah mencakup sekitar 33% seluruh korpus dan angka top-3 mudah tinggi. Peringkat 1 lebih menjanjikan sebagai ukuran mutu. Catatan: backend LSA hanya semantik ringan (hubungan antar kata dipelajari dari korpus yang kecil), sehingga parafrase yang benar-benar tidak berbagi kata akan sulit. Untuk hasil lebih kuat, pasang sentence-transformers; kode ini otomatis memakainya.

Lampiran: kode lab2_indeks_cari.py

```
"""Lab 2 - Bangun indeks & cari (25 menit).

1. Letakkan 3 PDF di folder dokumen/, jalankan indeks, pastikan tiap file melaporkan jumlah chunk.
2. Ajukan 5 pertanyaan dengan query(); periksa apakah chunk teratas benar-benar relevan.
3. Ajukan 2 pertanyaan berparafrase; apakah pencarian semantik tetap menemukannya?

Dokumen yang dipakai (3 PDF tentang kecerdasan buatan, semuanya di folder dokumen/):
  - 1_Pengantar_Kecerdasan_Buatan.pdf
  - 2_Machine_Learning_dan_Deep_Learning.pdf
  - 3_Etika_dan_Masa_Depan_AI.pdf
"""
import io
import os
import sys
from contextlib import redirect_stdout

sys.path.insert(0, os.path.dirname(os.path.abspath(__file__)))
from laporan_utils import Laporan
from rag_utils import bangun_indeks, cocok, query

BASE = os.path.dirname(os.path.abspath(__file__))
UKURAN, OVERLAP = 1000, 0.15
FILE_DIHARAPKAN = [
    "1_Pengantar_Kecerdasan_Buatan.pdf",
    "2_Machine_Learning_dan_Deep_Learning.pdf",
    "3_Etika_dan_Masa_Depan_AI.pdf",
]

# kw = kata kunci yang HARUS ada di chunk teratas agar dianggap relevan
# "sumber" = PDF yang memuat jawabannya (hanya untuk catatan di laporan)
PERTANYAAN = [
    {"q": "Siapa yang memperkenalkan istilah Artificial Intelligence dan pada tahun berapa?",
     "kw": ["McCarthy", "1956"], "sumber": "PDF 1"},
    {"q": "Komputer apa yang mengalahkan juara catur dunia Garry Kasparov?",
     "kw": ["Deep Blue", "Kasparov"], "sumber": "PDF 1"},
    {"q": "Apa perbedaan supervised learning dan unsupervised learning?",
     "kw": ["Supervised Learning", "Unsupervised Learning"], "sumber": "PDF 2"},
    {"q": "Apa yang dimaksud dengan overfitting?",
     "kw": ["overfitting", "menghafal"], "sumber": "PDF 2"},
    {"q": "Arsitektur apa yang mendasari model bahasa besar modern?",
     "kw": ["Transformer", "mendasari"], "sumber": "PDF 2"},
]
PARAFRASE = [
    {"q": "Bagaimana komputer bisa belajar dari contoh tanpa diberi aturan langkah demi langkah?",
     "kw": ["tanpa diprogram"], "sumber": "PDF 1",
     "catatan": "Teks memakai 'tanpa diprogram secara eksplisit'; pertanyaan memakai 'tanpa diberi aturan
     langkah demi langkah'."},
    {"q": "Mengapa program komputer bisa memperlakukan kelompok orang tertentu secara berbeda?",
     "kw": ["diskriminasi", "mewarisi"], "sumber": "PDF 3",
     "catatan": "Teks memakai 'bias', 'diskriminasi', dan 'mewarisi'; pertanyaan memakai 'memperlakukan
    kelompok tertentu secara berbeda'."},
]


def ringkas(t, n=150):
    t = " ".join(t.split())
    return t if len(t) <= n else t[:n] + "..."


def jalankan(indeks, daftar, k=3):
    hasil = []
    for s in daftar:
        atas = query(indeks, s["q"], k)
        rel = [cocok(a["teks"], s["kw"]) for a in atas]
        hasil.append((s, atas, rel))
    return hasil


def main():
    # ---- Langkah 1
    print("=== Langkah 1: membangun indeks ===")
    buf = io.StringIO()
    with redirect_stdout(buf):
        idx = bangun_indeks(ukuran=UKURAN, overlap=OVERLAP, backend="auto")
    log_indeks = buf.getvalue()
    print(log_indeks)
    idx_leksikal = bangun_indeks(ukuran=UKURAN, overlap=OVERLAP, backend="tfidf", verbose=False)
    per_file = {}
    for m in idx.meta:
        per_file[m["file"]] = per_file.get(m["file"], 0) + 1
```

```
hilang = [f for f in FILE_DIHARAPKAN if f not in per_file]
if hilang:
    print("PERINGATAN: file belum terindeks (cek folder dokumen/):", ", ".join(hilang))
total = len(idx.chunks)

# ---- Langkah 2
print("=== Langkah 2: 5 pertanyaan ===")
h2 = jalankan(idx, PERTANYAAN)
for s, atas, rel in h2:
    print(f"\nQ: {s['q']}  (kata kunci: {s['kw']}; jawaban di {s['sumber']})")
    for r, (a, ok) in enumerate(zip(atas, rel), 1):
        print(f"  #{r} skor={a['skor']:.3f} {a['file']}#{a['no']} relevan={ok} |
{ringkas(a['teks'])}")
n_top1 = sum(rel[0] for _, _, rel in h2)
n_top3 = sum(any(rel) for _, _, rel in h2)

# ---- Langkah 3
print("\n=== Langkah 3: parafrase ===")
sem = jalankan(idx, PARAFRASE)
lek = jalankan(idx_leksikal, PARAFRASE)
for (s, a1, r1), (_, a2, r2) in zip(sem, lek):
    print(f"\nQ: {s['q']}")
    print(f"  {idx.backend}: top1 relevan={r1[0]} top3 relevan={any(r1)} |
{a1[0]['file']}#{a1[0]['no']}")
    print(f"  tfidf : top1 relevan={r2[0]} top3 relevan={any(r2)} | {a2[0]['file']}#{a2[0]['no']}")

# ---- Kesimpulan dari angka
sem_top3 = sum(any(r) for _, _, r in sem)
lek_top3 = sum(any(r) for _, _, r in lek)
sem_top1 = sum(r[0] for _, _, r in sem)
lek_top1 = sum(r[0] for _, _, r in lek)
kes = (f"Pada 5 pertanyaan langsung, chunk peringkat 1 relevan pada {n_top1}/5 pertanyaan dan salah
satu dari "
       f"3 chunk teratas relevan pada {n_top3}/5 pertanyaan. Pada 2 pertanyaan parafrase, backend "
       f"'{idx.backend}' menemukan chunk relevan di peringkat 1 pada {sem_top1}/2 dan di 3 teratas
pada "
       f"{sem_top3}/2, sedangkan pembanding TF-IDF (kecocokan bentuk kata) {lek_top1}/2 dan
{lek_top3}/2. ")
gagal_top1 = [s["q"] for s, atas, rel in h2 if not rel[0]]
if gagal_top1:
    kes += ("Pertanyaan yang chunk peringkat 1-nya belum relevan: " + "; ".join(f'"{q}"' for q in
gagal_top1) +
            ". Penyebab yang mungkin: kalimat jawaban terbelah di batas chunk sehingga kata kuncinya
"
            "terpisah, sementara chunk di sebelahnya memuat topik yang mirip. ")
if sem_top1 == lek_top1 and sem_top3 == lek_top3:
    kes += ("Pada dua parafrase ini, semantik dan TF-IDF memberi hasil yang sama, jadi tes ini belum
bisa "
            "membedakan keduanya; kemungkinan karena pertanyaan masih berbagi beberapa kata dengan
teks "
            "dan TF-IDF n-gram karakter menangkap variasi bentuk kata. ")
kes += (f"Perlu diingat korpusnya sangat kecil: hanya {total} chunk dari {len(per_file)} PDF,
sehingga 3 chunk "
        f"teratas sudah mencakup sekitar {min(3, total) / total:.0%} seluruh korpus dan angka top-3
mudah "
        "tinggi. Peringkat 1 lebih menjanjikan sebagai ukuran mutu. ")
if idx.backend == "lsa":
    kes += ("Catatan: backend LSA hanya semantik ringan (hubungan antar kata dipelajari dari korpus
yang kecil), "
            "sehingga parafrase yang benar-benar tidak berbagi kata akan sulit. Untuk hasil lebih
kuat, pasang "
            "sentence-transformers; kode ini otomatis memakainya.")
print("\nKesimpulan:", kes)

# ---- Laporan PDF
L = Laporan(os.path.join(BASE, "Lab2_Indeks_dan_Pencarian.pdf"), "Lab 2 - Bangun Indeks & Cari",
            f"ukuran chunk {UKURAN}, overlap {int(OVERLAP * 100)}%, backend: {idx.backend}")
L.h1("Langkah 1. Membangun indeks")
L.p("Tiga PDF diletakkan di folder dokumen/. Setiap file melaporkan jumlah chunk-nya:")
L.tabel([["File", "Jumlah chunk"]] + [[f, n] for f, n in per_file.items()] + [["Total", total]],
        [9 * 28.35, 4 * 28.35])
L.kode(log_indeks.rstrip())
if hilang:
    L.p("PERINGATAN: file berikut belum terindeks: " + ", ".join(hilang))
L.h1("Langkah 2. Lima pertanyaan dan pemeriksaan chunk teratas")
L.p("Sebuah chunk dianggap relevan bila memuat semua kata kunci jawaban. Tabel menunjukkan 3 chunk
teratas.")
for s, atas, rel in h2:
    L.h2(f"{s['q']} (jawaban di {s['sumber']})")
    L.tabel([["Peringkat", "Skor", "Sumber", "Relevan?", "Cuplikan"]] +
            [[r, f"{a['skor']:.3f}", f"{a['file']} #{a['no']}", "ya" if ok else "tidak",
ringkas(a["teks"], 140)]
             for r, (a, ok) in enumerate(zip(atas, rel), 1)],
```

```
                [1.6 * 28.35, 1.3 * 28.35, 3.8 * 28.35, 1.6 * 28.35, 8.7 * 28.35])
    L.p(f"Ringkasan: chunk peringkat 1 relevan pada {n_top1}/5 pertanyaan; ada chunk relevan di 3 teratas
     pada {n_top3}/5.")
    L.h1("Langkah 3. Pertanyaan berparafrase")
    L.p("Dua pertanyaan memakai kata yang berbeda dari teks dokumen. Dibandingkan: pencarian semantik "
        f"({idx.backend}) vs TF-IDF.")
    baris = [["Pertanyaan", "Catatan", f"{idx.backend}: top1 / top3", "TF-IDF: top1 / top3"]]
    for (s, a1, r1), (_, a2, r2) in zip(sem, lek):
        baris.append([s["q"], s["catatan"], f"{'ya' if r1[0] else 'tidak'} / {'ya' if any(r1) else
    'tidak'}",
                      f"{'ya' if r2[0] else 'tidak'} / {'ya' if any(r2) else 'tidak'}"])
    L.tabel(baris, [5 * 28.35, 6 * 28.35, 3 * 28.35, 3 * 28.35])
    for (s, a1, r1), _ in zip(sem, lek):
        L.p(f"Chunk teratas untuk \"{s['q']}\": {a1[0]['file']} #{a1[0]['no']} (skor
    {a1[0]['skor']:.3f})")
        L.kode(ringkas(a1[0]["teks"], 400))
    L.h1("Kesimpulan")
    L.p(kes)
    L.halaman_baru()
    L.h1("Lampiran: kode lab2_indeks_cari.py")
    L.kode(open(__file__, encoding="utf-8").read())
    L.simpan()
    print("\nLaporan: Lab2_Indeks_dan_Pencarian.pdf")


if __name__ == "__main__":
    main()
```