Lab 3 - Ukur Hit@k

backend: lsa | overlap 15% | koleksi ukuran 500 dan 1000

Langkah 1. Lima belas pertanyaan uji

Soal dibuat dari tiga dokumen di folder dokumen/ (lima soal per dokumen). Sebuah chunk dianggap benar bila memuat semua kata kunci jawaban. Sebanyak 6 soal bernada langsung dan 9 soal diparafrase (kata-katanya sengaja berbeda dari teks).

No	Jenis	Pertanyaan	Kata kunci
1	langsung	Siapa yang memperkenalkan istilah Artificial Intelligence pada konferensi Dartmouth?	McCarthy
2	parafrase	Siapa tokoh yang bertanya apakah mesin dapat berpikir?	Turing
3	parafrase	Mesin buatan IBM apa yang menang atas pemain catur terbaik dunia pada 1997?	Deep Blue
4	parafrase	Jenis AI apa yang hanya mampu mengerjakan satu tugas spesifik?	Narrow AI
5	parafrase	Bidang AI apa yang membuat mesin mampu memahami gambar dan video?	Computer Vision
6	langsung	Paradigma pembelajaran apa yang memakai data berlabel?	berlabel
7	parafrase	Bagaimana cara mengelompokkan pelanggan tanpa memakai label?	clustering
8	langsung	Arsitektur jaringan saraf apa yang umum dipakai untuk pengolahan gambar?	Convolutional
9	langsung	Apa yang dimaksud dengan overfitting?	overfitting
10	langsung	Arsitektur apa yang mendasari model bahasa besar modern?	Transformer
11	langsung	Regulasi apa di Uni Eropa yang mengatur kecerdasan buatan?	EU AI Act
12	parafrase	Organisasi internasional apa yang menerbitkan pedoman etika AI?	UNESCO
13	parafrase	Mengapa program komputer bisa memperlakukan kelompok orang tertentu secara berbeda?	mewarisi
14	parafrase	Apa istilah untuk konten palsu buatan AI yang tampak meyakinkan?	deepfake
15	parafrase	Upaya apa yang disarankan agar pekerja siap menghadapi otomatisasi?	upskilling

Langkah 2. Hasil Hit@k

Koleksi	Hit@1	Hit@3	Hit@5	Jumlah chunk
ukuran 500	0.933	0.933	0.933	15
ukuran 1000	0.800	1.000	1.000	9

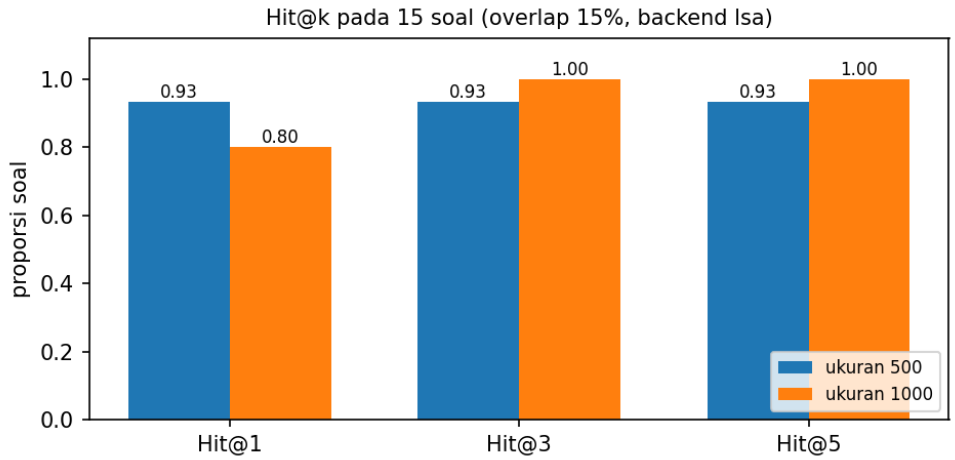

Hit@5 menurut jenis soal

Jenis soal	Jumlah	ukuran 500	ukuran 1000
langsung	6	1.000	1.000
parafrase	9	0.889	1.000

Peringkat chunk pertama yang memuat jawaban, per soal

Angka 1 berarti chunk teratas sudah benar. Angka > 5 berarti gagal pada Hit@5.

No	Jenis	Peringkat (ukuran 500)	Peringkat (ukuran 1000)
1	langsung	1	1
2	parafrase	1	1
3	parafrase	1	1
4	parafrase	1	1
5	parafrase	1	1
6	langsung	1	1
7	parafrase	1	1
8	langsung	1	1
9	langsung	1	1
10	langsung	1	1
11	langsung	1	2
12	parafrase	1	1
13	parafrase	6	3
14	parafrase	1	1
15	parafrase	1	2

Diagnosis soal yang gagal (k=5)

Ukuran	No	Pertanyaan	Diagnosis
500	13	Mengapa program komputer bisa memperlakukan kelompok orang tertentu secara berbeda?	chunk jawaban ada tetapi baru muncul di peringkat 6 (> 5)

Langkah 3. Kesimpulan

Ukuran 1000 karakter lebih baik: Hit@1/3/5 = 0.80/1.00/1.00 dibanding 0.93/0.93/0.93 pada ukuran 500. Pada k=5, pertanyaan yang gagal: ukuran 500 -> no. 13; ukuran 1000 -> tidak ada. Dugaan penyebab: kosakata pertanyaan berbeda dari kosakata dokumen (terutama pada soal parafrase), sehingga chunk lain yang topiknya lebih umum mendapat skor kemiripan lebih tinggi. Catatan: skor terbaik mendekati sempurna karena korpus hanya 3 dokumen kecil (9-15 chunk) dengan topik yang jelas berbeda (pada ukuran 500, k=5 sudah mencakup 33% dari 15 chunk; pada ukuran 1000, k=5 sudah mencakup 56% dari 9 chunk); pada PDF yang lebih besar dan lebih mirip antar dokumen, Hit@k diperkirakan turun dan perbedaan antar ukuran chunk akan lebih terlihat.

Lampiran: kode lab3_hit_at_k.py

```
"""Lab 3 - Ukur Hit@k (25 menit).

1. 15 pertanyaan uji beserta kata kunci jawaban dari dokumen.
2. hit_at_k untuk k = 1, 3, 5 pada dua koleksi dengan ukuran chunk berbeda.
3. Kesimpulan 3-4 kalimat: ukuran terbaik, pertanyaan yang gagal, dugaan penyebab.

Dokumen yang dipakai (3 PDF tentang kecerdasan buatan, semuanya di folder dokumen/):
  - 1_Pengantar_Kecerdasan_Buatan.pdf
  - 2_Machine_Learning_dan_Deep_Learning.pdf
  - 3_Etika_dan_Masa_Depan_AI.pdf
"""
import os
import sys

import matplotlib
matplotlib.use("Agg")
import matplotlib.pyplot as plt

sys.path.insert(0, os.path.dirname(os.path.abspath(__file__)))
from laporan_utils import Laporan
from rag_utils import FOLDER_DOKUMEN, baca_pdf, bangun_indeks, cocok, hit_at_k, norm, peringkat_hit

BASE = os.path.dirname(os.path.abspath(__file__))
OVERLAP = 0.15
UKURAN = (500, 1000)          # dua koleksi yang dibandingkan
KS = (1, 3, 5)

SOAL = [  # q = pertanyaan, kw = kata kunci yang harus ada di chunk jawaban, jenis = langsung / parafrase
    # --- 1_Pengantar_Kecerdasan_Buatan.pdf
    {"q": "Siapa yang memperkenalkan istilah Artificial Intelligence pada konferensi Dartmouth?", "kw":
    ["McCarthy"], "jenis": "langsung"},
    {"q": "Siapa tokoh yang bertanya apakah mesin dapat berpikir?", "kw": ["Turing"], "jenis":
    "parafrase"},
    {"q": "Mesin buatan IBM apa yang menang atas pemain catur terbaik dunia pada 1997?", "kw": ["Deep
    Blue"], "jenis": "parafrase"},
    {"q": "Jenis AI apa yang hanya mampu mengerjakan satu tugas spesifik?", "kw": ["Narrow AI"], "jenis":
     "parafrase"},
    {"q": "Bidang AI apa yang membuat mesin mampu memahami gambar dan video?", "kw": ["Computer Vision"],
     "jenis": "parafrase"},
    # --- 2_Machine_Learning_dan_Deep_Learning.pdf
    {"q": "Paradigma pembelajaran apa yang memakai data berlabel?", "kw": ["berlabel"], "jenis":
    "langsung"},
    {"q": "Bagaimana cara mengelompokkan pelanggan tanpa memakai label?", "kw": ["clustering"], "jenis":
    "parafrase"},
    {"q": "Arsitektur jaringan saraf apa yang umum dipakai untuk pengolahan gambar?", "kw":
    ["Convolutional"], "jenis": "langsung"},
    {"q": "Apa yang dimaksud dengan overfitting?", "kw": ["overfitting"], "jenis": "langsung"},
    {"q": "Arsitektur apa yang mendasari model bahasa besar modern?", "kw": ["Transformer"], "jenis":
    "langsung"},
    # --- 3_Etika_dan_Masa_Depan_AI.pdf
    {"q": "Regulasi apa di Uni Eropa yang mengatur kecerdasan buatan?", "kw": ["EU AI Act"], "jenis":
    "langsung"},
    {"q": "Organisasi internasional apa yang menerbitkan pedoman etika AI?", "kw": ["UNESCO"], "jenis":
    "parafrase"},
    {"q": "Mengapa program komputer bisa memperlakukan kelompok orang tertentu secara berbeda?", "kw":
    ["mewarisi"], "jenis": "parafrase"},
    {"q": "Apa istilah untuk konten palsu buatan AI yang tampak meyakinkan?", "kw": ["deepfake"],
    "jenis": "parafrase"},
    {"q": "Upaya apa yang disarankan agar pekerja siap menghadapi otomatisasi?", "kw": ["upskilling"],
    "jenis": "parafrase"},
]


def diagnosis(idx, soal, k):
    """Tebak penyebab gagal secara otomatis dari data (bukan menebak sembarang)."""
    r = peringkat_hit(idx, soal)
    if r is None:
        return "kata kunci terbelah di batas chunk (tidak ada satu chunk pun yang memuatnya utuh)"
    return f"chunk jawaban ada tetapi baru muncul di peringkat {r} (> {k})"


def main():
    # sanity check: setiap kata kunci memang ada di dokumen asli
    korpus = norm(" ".join(baca_pdf(os.path.join(FOLDER_DOKUMEN, f))
                           for f in sorted(os.listdir(FOLDER_DOKUMEN)) if f.endswith(".pdf")))
    for s in SOAL:
        assert all(norm(k) in korpus for k in s["kw"]), f"kata kunci tidak ada di dokumen: {s}"

    koleksi, hasil = {}, {}
    for u in UKURAN:
```

```
    print(f"\n=== Koleksi ukuran {u} ===")
    koleksi[u] = bangun_indeks(ukuran=u, overlap=OVERLAP, backend="auto")
    hasil[u] = {k: hit_at_k(koleksi[u], SOAL, k) for k in KS}
    print({f"Hit@{k}": round(v, 3) for k, v in hasil[u].items()})
backend = koleksi[UKURAN[0]].backend

ranks = {u: [peringkat_hit(koleksi[u], s) for s in SOAL] for u in UKURAN}

# ---- kesimpulan otomatis
kunci = lambda u: (hasil[u][5], hasil[u][3], hasil[u][1])
a, b = UKURAN
terbaik = a if kunci(a) > kunci(b) else b if kunci(b) > kunci(a) else None
fmt = lambda u: "/".join(f"{hasil[u][k]:.2f}" for k in KS)
if terbaik:
    lain = b if terbaik == a else a
    s1 = (f"Ukuran {terbaik} karakter lebih baik: Hit@1/3/5 = {fmt(terbaik)} dibanding {fmt(lain)}
pada "
          f"ukuran {lain}.")
else:
    s1 = f"Kedua ukuran seimbang: Hit@1/3/5 = {fmt(a)} (ukuran {a}) dan {fmt(b)} (ukuran {b})."
gagal = {u: [i for i, r in enumerate(ranks[u], 1) if r is None or r > 5] for u in UKURAN}
s2 = "Pada k=5, pertanyaan yang gagal: " + "; ".join(
    f"ukuran {u} -> " + (", ".join(f"no. {i}" for i in gagal[u]) if gagal[u] else "tidak ada") for u
in UKURAN) + "."
penyebab = {}
for u in UKURAN:
    for i in gagal[u]:
        penyebab[(u, i)] = diagnosis(koleksi[u], SOAL[i - 1], 5)
print("\nDiagnosis gagal (k=5):")
for (u, i), c in penyebab.items():
    print(f"  ukuran {u}, no. {i} ({SOAL[i-1]['q']}): {c}")

# hit@k per jenis soal (langsung vs parafrase)
per_jenis = {}
for jenis in ("langsung", "parafrase"):
    sub = [s for s in SOAL if s["jenis"] == jenis]
    per_jenis[jenis] = (len(sub), {u: hit_at_k(koleksi[u], sub, 5) for u in UKURAN})

# kalimat 3: dugaan penyebab berdasarkan jenis diagnosis
if penyebab:
    terbelah = [x for x in penyebab.values() if x.startswith("kata kunci terbelah")]
    peringkat = [x for x in penyebab.values() if x.startswith("chunk jawaban ada")]
    dugaan = []
    if peringkat:
        dugaan.append("kosakata pertanyaan berbeda dari kosakata dokumen (terutama pada soal
parafrase), "
                      "sehingga chunk lain yang topiknya lebih umum mendapat skor kemiripan lebih
tinggi")
    if terbelah:
        dugaan.append("kata kunci jawaban terbelah di batas chunk dan overlap belum cukup
menyelamatkannya")
    s3 = "Dugaan penyebab: " + "; serta ".join(dugaan) + "."
else:
    s3 = "Tidak ada kegagalan pada k=5, sehingga tidak ada penyebab yang perlu dianalisis."
n_chunk = {u: len(koleksi[u].chunks) for u in UKURAN}
rentang = f"{min(n_chunk.values())}-{max(n_chunk.values())} chunk"
cakup = "; ".join(f"pada ukuran {u}, k=5 sudah mencakup {min(5, n_chunk[u]) / n_chunk[u]:.0%} dari
{n_chunk[u]} chunk"
                  for u in UKURAN)
if max(hasil[u][5] for u in UKURAN) >= 0.9:
    s4 = (f"Catatan: skor terbaik mendekati sempurna karena korpus hanya 3 dokumen kecil ({rentang})
dengan topik yang "
          f"jelas berbeda ({cakup}); pada PDF yang lebih besar dan lebih mirip antar dokumen, Hit@k "
          "diperkirakan turun dan perbedaan antar ukuran chunk akan lebih terlihat.")
else:
    s4 = (f"Catatan: korpus hanya 3 dokumen kecil ({rentang}; {cakup}), sehingga satu soal yang gagal
 sudah "
          "mengubah skor cukup besar; hasil ini belum tentu berlaku pada PDF yang lebih besar.")
kesimpulan = " ".join([s1, s2, s3, s4])
print("\nKesimpulan:", kesimpulan)

# grafik
fig, ax = plt.subplots(figsize=(6.4, 3.2), dpi=150)
lebar = 0.35
for j, u in enumerate(UKURAN):
    xs = [i + (j - 0.5) * lebar for i in range(len(KS))]
    bars = ax.bar(xs, [hasil[u][k] for k in KS], lebar, label=f"ukuran {u}")
    ax.bar_label(bars, fmt="%.2f", fontsize=8)
ax.set_xticks(range(len(KS)), [f"Hit@{k}" for k in KS])
ax.set_ylim(0, 1.12)
ax.set_ylabel("proporsi soal")
ax.set_title(f"Hit@k pada {len(SOAL)} soal (overlap {int(OVERLAP * 100)}%, backend {backend})",
fontsize=10)
```

```
    ax.legend(loc="lower right", fontsize=8)
    fig.tight_layout()
    gambar = os.path.join(BASE, "_grafik_hit_at_k.png")
    fig.savefig(gambar)
    plt.close(fig)

    # laporan PDF
    W = 28.35
    L = Laporan(os.path.join(BASE, "Lab3_Hit_at_k.pdf"), "Lab 3 - Ukur Hit@k",
                f"backend: {backend} | overlap {int(OVERLAP * 100)}% | koleksi ukuran {UKURAN[0]} dan
    {UKURAN[1]}")
    L.h1("Langkah 1. Lima belas pertanyaan uji")
    n_lgs = sum(s["jenis"] == "langsung" for s in SOAL)
    L.p("Soal dibuat dari tiga dokumen di folder dokumen/ (lima soal per dokumen). Sebuah chunk dianggap
    benar "
        f"bila memuat semua kata kunci jawaban. Sebanyak {n_lgs} soal bernada langsung dan {len(SOAL) -
    n_lgs} "
        "soal diparafrase (kata-katanya sengaja berbeda dari teks).")
    L.tabel([["No", "Jenis", "Pertanyaan", "Kata kunci"]] +
            [[i, s["jenis"], s["q"], ", ".join(s["kw"])] for i, s in enumerate(SOAL, 1)],
            [1 * W, 2 * W, 10 * W, 4 * W])
    L.h1("Langkah 2. Hasil Hit@k")
    L.tabel([["Koleksi"] + [f"Hit@{k}" for k in KS] + ["Jumlah chunk"]] +
            [[f"ukuran {u}"] + [f"{hasil[u][k]:.3f}" for k in KS] + [len(koleksi[u].chunks)] for u in
    UKURAN],
            [4 * W, 2.5 * W, 2.5 * W, 2.5 * W, 3 * W])
    L.gambar(gambar, 13)
    L.h2("Hit@5 menurut jenis soal")
    L.tabel([["Jenis soal", "Jumlah"] + [f"ukuran {u}" for u in UKURAN]] +
            [[j, n] + [f"{v[u]:.3f}" for u in UKURAN] for j, (n, v) in per_jenis.items()],
            [4 * W, 2.5 * W, 3 * W, 3 * W])
    L.h2("Peringkat chunk pertama yang memuat jawaban, per soal")
    L.p("Angka 1 berarti chunk teratas sudah benar. Angka > 5 berarti gagal pada Hit@5.")
    L.tabel([["No", "Jenis", f"Peringkat (ukuran {UKURAN[0]})", f"Peringkat (ukuran {UKURAN[1]})"]] +
            [[i, s["jenis"], ranks[UKURAN[0]][i - 1], ranks[UKURAN[1]][i - 1]] for i, s in
    enumerate(SOAL, 1)],
            [1.2 * W, 3 * W, 5 * W, 5 * W])
    if penyebab:
        L.h2("Diagnosis soal yang gagal (k=5)")
        L.tabel([["Ukuran", "No", "Pertanyaan", "Diagnosis"]] +
                [[u, i, SOAL[i - 1]["q"], c] for (u, i), c in penyebab.items()], [1.5 * W, 1 * W, 7 * W,
    8 * W])
    L.h1("Langkah 3. Kesimpulan")
    L.p(kesimpulan)
    L.halaman_baru()
    L.h1("Lampiran: kode lab3_hit_at_k.py")
    L.kode(open(__file__, encoding="utf-8").read())
    L.simpan()
    os.remove(gambar)
    print("\nLaporan: Lab3_Hit_at_k.pdf")


if __name__ == "__main__":
    main()
```